МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РФ

НОВОСИБИРСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ

ФАКУЛЬТЕТ ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ

Отчет по лабораторной работе №4

по курсу «Архитектура современных микропроцессоров и мультипроцессоров»

ОПРЕДЕЛЕНИЕ МАКСИМАЛЬНО ДОСТИЖИМЫХ СКОРОСТЕЙ ЧТЕНИЯ, ЗАПИСИ И КОПИРОВАНИЯ ДАННЫХ В RAM

Выполнил: студент 3-го курса гр. 17208

Гафиятуллин А.Р

Новосибирск, 2020

1. **ЦЕЛИ РАБОТЫ:**
   1.1. научиться определять максимально достижимые скорости чтения, записи и копирования данных в оперативной памяти.
2. **ЗАДАЧИ РАБОТЫ:**
   2.1. Написать подпрограммы, наиболее быстро выполняющие операции чтения, записи и копирования данных одним потоком.
   2.2. Написать программу, определяющую максимально возможную скорость чтения, записи и копирования данных при одновременном выполнении операции заданным числом потоков.
   2.3. Определить максимальную скорость чтения, записи, копирования данных (в GB/s) для двух различных многоядерных вычислительных систем для числа потоков от 1 до числа ядер. Сравнить полученные результаты с техническими характеристиками вычислительных систем. По результатам исследования сделать вывод.
3. **ТЕСТИРУЕМЫЕ СИТСЕМЫ:**
   3.1. Персональный компьютер:
   - **Процессор**: Intel® Core™ i7-9700F:
     - **Кол-во ядер:** 8;
     - **Поддерживаемый тип памяти:** DDR4-2666;
     - **Максимальная пропускная способность памяти:** 42.6 GB/s;
     - **Количество каналов памяти:** 2.
   - **Память**:
     - **Объем:** 32 Гб;
     - **Эффективная частота:** 2666 МГц;
     - **Режим работы:** двухканальный.
   - **Компилятор**: Intel(R) C++ Intel(R) 64 Compiler for applications running on Intel(R) 64, Version 19.1.1.216 Build 20200306;
   - **Ключи компиляции (наиболее важные**): /O2 /arch:AVX2 /tune:coffeelake /Qopenmp;

   3.2. Блейд-сервер HP BL2x220c G7:
   - **Процессор:** 2 x Intel Xeon X5670:
     - **Кол-во ядер:** 12;
     - **Поддерживаемый тип памяти**: DDR3 800/1066/1333;
     - **Максимальная пропускная способность памяти:** 64 GB/s;
     - **Количество каналов памяти:** 6.
   - **Память:**
     - **Объем:** 24 Гб;

- **Эффективная частота:** 1333 МГц;
- **Режим работы:** шестиканальный.

- **Компилятор**: gcc version 4.8.5
- **Ключи компиляции:** -std=c++11 -msse4.1 -fopenmp -O2

3.3.Размеры массивов для тестирования: 512 Мбайт.

4. ХОД РАБОТЫ:

4.1.Написание подпрограмм:

- **Тип данных:** __m128i;
- **Использование операций чтения/записи без доступа в кэш:** да;
- **Раскрутка циклов:** нет (не дало заметного эффекта);
- **Использование библиотечных функций memchr, memset, memcpy**: нет в местах замера времени.
- Подпрограммы:
  - Запись:

```
double test_write(__m128i *buffer, __m128i init_element) {
    double start = omp_get_wtime();
    for (size_t i = 0; i < BUFFER_SIZE / sizeof(__m128i); i++) {
        _mm_stream_si128(buffer + i, init_element);     // non-temporal write
    }
    double end = omp_get_wtime();

    return end - start;
}
```

  - Чтение:

```
double test_read(__m128i* buffer, int *res) {
    __m128i read_element;

    double start = omp_get_wtime();
    for (size_t i = 0; i < BUFFER_SIZE / sizeof(__m128i); i++) {
        read_element = _mm_stream_load_si128(buffer + i); // non-temporal read
    }
    double end = omp_get_wtime();

    // assign to prevent optimization
    *res += ((int*)&read_element)[2];

    return (end - start);
}
```

  - Копирование:

```
double test_copy(__m128i* buffer1, __m128i* buffer2) {
```

```
    double start = omp_get_wtime();
    for (size_t i = 0; i < BUFFER_SIZE / sizeof(__m128i); i++) {
        _mm_stream_si128(buffer2 + i, _mm_stream_load_si128(buffer1 + i));     //
 non-temporal read-write
    }
    double end = omp_get_wtime();

    return (end - start);
}
```

ВАЖНО: перед началом замера времени необходимо пройтись по массиву, например с помощью **memset.** Это связано с тем, что в современных ОС, реализующих механизм виртуальной памяти, память выделяется **постранично во время очень долгого аппаратного прерывания (PAGE FAULT).** Как оказалось, это очень сильно влияет на результаты.

4.2.Листинг многопоточной программы (см. Приложение 6.1-6.3).

4.3.Графики с результатами тестирования:

- Персональный компьютер:

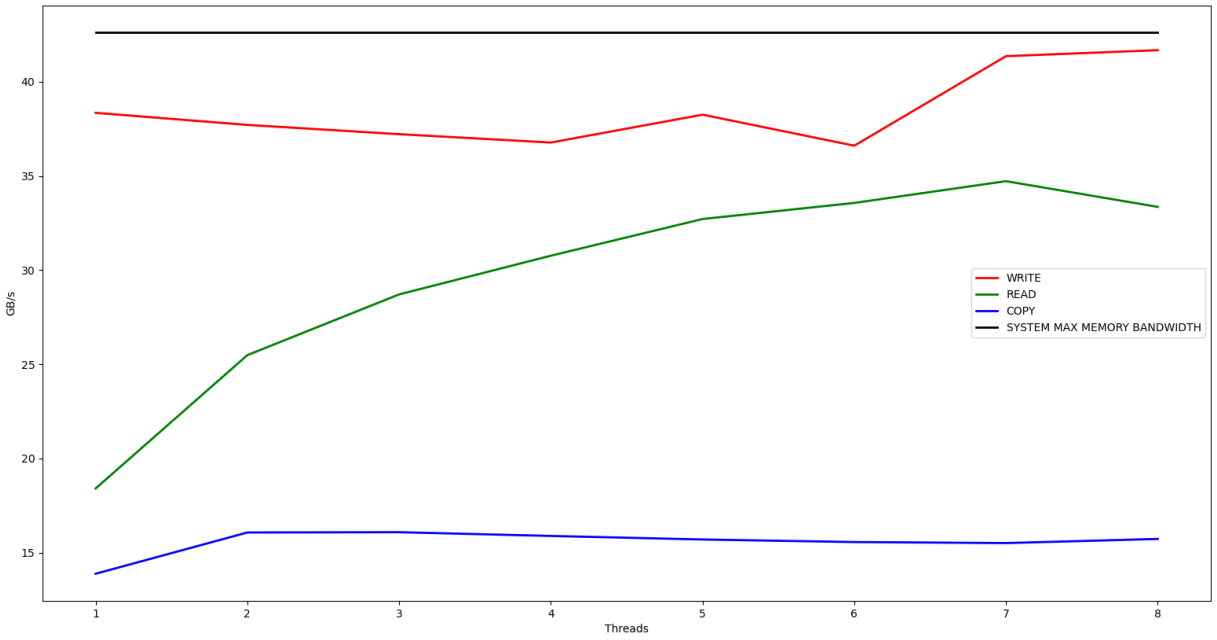

- HP BL2x220c G7:

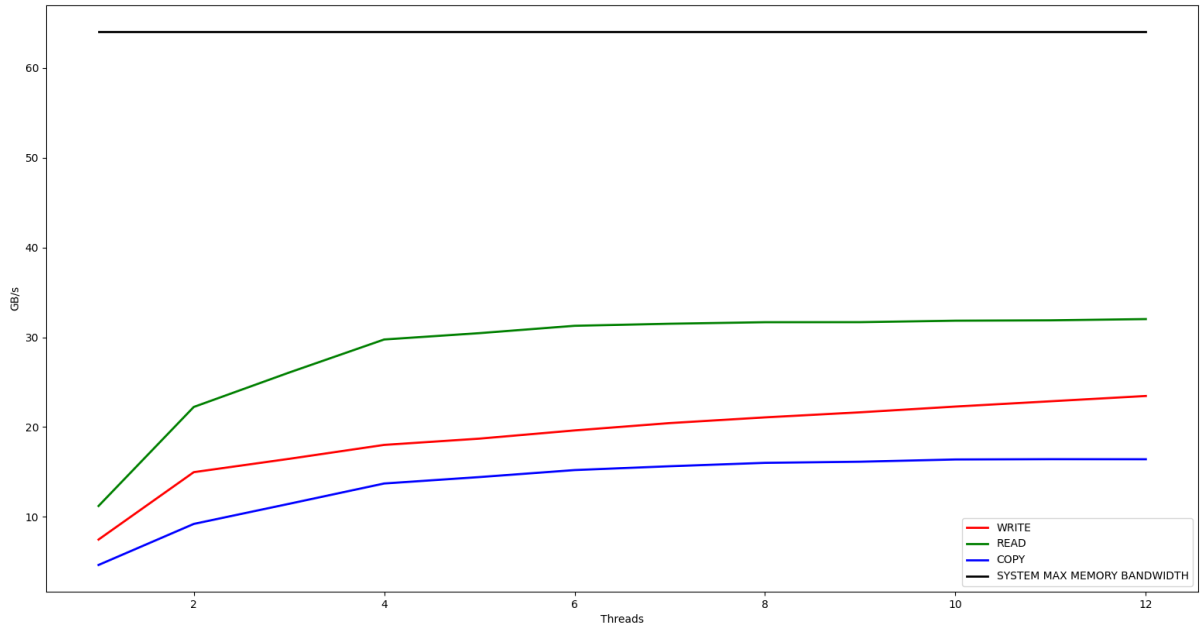

Черная линия: максимальная пропускная способность памяти;

Красная линия: запись;

Зеленая линия: чтение;

Синяя линия: копирование.

Так как сервер обычно довольно сильно загружен, то имеет смысл поближе рассмотреть результаты, полученные на относительно мощном персональном компьютере сразу после загрузки системы, на которой доступны удобные средства профилирования.

Что можно заметить на этом графике:

1. Самая быстрая операция – запись, причем скорость работы с памятью вплотную приближается к теоретической максимальной пропускной способности. К тому же она практически максимальная уже на 1 потоке;
2. Скорость работы с памятью при чтении растет постепенно с ростом кол-ва ядер;
3. Копирование самая медленная операция.

Чтобы объяснить эти результаты, было проведено профилирование кода на 1 и 8 потоках с помощью **Intel VTune Profiler 2020**:

Операция	Кол-во запросов к LLC на 1 потоке и % промахов		Кол-во запросов к LLC на 8 потоках и % промахов	
READ	520344028	46%	2491887058	90%
WRITE	29029812	23%	217047184	18%
COPY	658109478	44%	5020689024	89%

Какие выводы можно сделать из профилирования:

1. Кол-во запросов к LLC при операции чтения по крайней мере в **10**(на одном потоке вообще в **17**) раз больше, чем при операции записи и это при том, что используется специальный интринсик **_mm_stream_load_si128** при чтении и, казалось бы, эти показатели не должны отличаться;
2. При операции записи не только практически не происходит обращений к LLC (как и должно быть из-за интринсика **_mm_stream_si128**), так они еще и достаточно точные (если происходят);
3. Показатели обращений к LLC при копировании и чтении сравнимы, хотя у копирования они ожидаемо больше.

Возникает закономерный вопрос: почему **_mm_stream_load_si128** не работает в нашем случае и обращения к кэшу продолжаются?

Данная операция является оберткой над инструкцией **MOVNTDQA.** Intel специфицирует использование этой инструкции для регионов памяти, помеченных как **USWC** (uncachable speculative write combining). Обычная память такого типа не имеет. Для всех остальных регионов памяти вместо этой инструкции используется обычная **MOVDQA** даже при вызове **_mm_stream_load_si128,** причем, в таком случае, задействуются обычные (или почти обычные) политики кэширования данных. Учитывая большие размеры тестовых данных и отсутствие повторного их использования, очень много тактов тратится на проверки кэшей, что сильно замедляет работу с памятью.

Отсюда вытекают следующие выводы:

1. Для записи почти максимальная пропускная способность может быть достигнута уже на одном потоке, потому что нет трат времени на ожидания ответа от кэшей;
2. При чтении нет возможности достигнуть максимальную пропускную способность сразу из-за долгого ожидания ответа от кэшей, который еще и сообщит о промахе, и все равно придется сходить в память. Большая часть пропускной способности шины остается незанятой, поэтому увеличение кол-ва потоков позволяет заполнить это незанятое пространство, так как на реальных ядрах они могут выполняться действительно параллельно;
3. Скорости копирования такие небольшие, потому что там есть медленное чтение. Так же вносит свои коррективы работа с двумя массивами и запись.

Для сравнения результаты встроенного в **AIDA64 Extreme** бенчмарка памяти. На сайте разработчика указано, что этот бенчмарк использует хорошо оптимизированные архитектурно-специфичные инструкции:

Чтение:

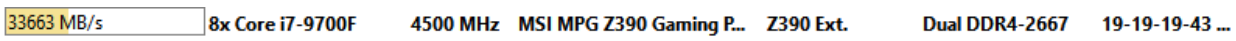

(**33.663 Гб/с** – примерно такой же результат получен и в написанной программе).

Запись:

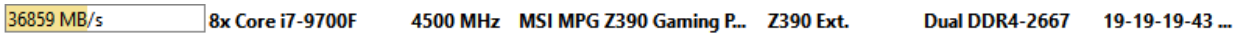

(36.859 Гб/с - примерно такой же результат получен и в написанной программе, причем скорость записи так же выше скорости чтения).

Копирование:

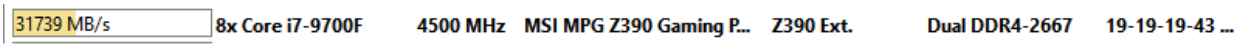

(31.789 Гб/с – так же самая низкая, но в два раза выше той, которая была получена в написанной программе. Видимо, действительно очень оптимизированные бенчмарки).

Результаты, полученные на сервере:

1. В отличие от персонального компьютера, здесь самая быстрая операция — это чтение (интересно, почему? Возможно, из-за нагрузки на сервер и т. д.);
2. Чтение в два раза медленнее максимальной пропускной способности;
3. Копирование осталось самой медленной операцией.

На кластере также был запущен бенчмарк **STREAM.** Из интересующих операций он замерил скорость копирования, которая составила **15.617 Гб/с**, что совпало с результатами, полученными написанной программой.

5. ВЫВОДЫ:

5.1. Научились определять максимально достижимые скорости чтения, записи и копирования данных в оперативной памяти;

5.2. Нужно быть осторожным при работе с виртуальной памятью, она может испортить производительность;

5.3. Некоторые интринсики имеют довольно узкие границы применимости.

6. ПРИЛОЖЕНИЕ:

6.1. **Чтение:**

```
#include <iostream>
#include <chrono>
#include <emmintrin.h>
#include <smmintrin.h>
#include <omp.h>
#include <vector>
#include <algorithm>
#include <cstring>
#include <cstdlib>

#ifdef _WIN32
#include <windows.h>    // for SetThreadAffinityMask
#elif __linux__
#include <sched.h>  // for sched_setaffinity
#endif

constexpr int ALIGN = 32;

constexpr size_t MBYTES = 512; // test array volume
constexpr size_t BUFFER_SIZE = 1024 * 1024 * MBYTES;
constexpr int TEST_TRIES = 50;
```

```
double test_read(__m128i* buffer, int *res) {
    __m128i read_element;

    double start = omp_get_wtime();
    for (size_t i = 0; i < BUFFER_SIZE / sizeof(__m128i); i++) {
        read_element = _mm_stream_load_si128(buffer + i); // non-temporal read
    }
    double end = omp_get_wtime();

    // assign to prevent optimization
    *res += ((int*)&read_element)[2];

    return (end - start);
}

void set_thread_affinity(int max_threads) {
#pragma omp parallel num_threads(max_threads)
    {
#ifdef _WIN32
    DWORD_PTR mask = (1 << omp_get_thread_num());
    SetThreadAffinityMask(GetCurrentThread(), mask);
#elif __linux__
    int cpu = omp_get_thread_num();
    cpu_set_t cpuset;
    CPU_ZERO(&cpuset);
    CPU_SET(cpu , &cpuset);
    sched_setaffinity(0, sizeof(cpuset), &cpuset);
#endif
    }
}

int main(int argc, char *argv[]) {
    int cores_num = 1;

    if(argc >= 2) {
        cores_num = atoi(argv[1]);
    }

    set_thread_affinity(cores_num);

    double curr_speed = 0;
    double result = 0;
    int res = 0;
#pragma omp parallel num_threads(cores_num)
        {
```

```
            for (int j = 0; j < TEST_TRIES; j++) {
#pragma omp single
                curr_speed = 0;
                __m128i* buffer = (__m128i*)_mm_malloc(BUFFER_SIZE, ALIGN);

                memset(buffer, 0, BUFFER_SIZE);
#pragma omp barrier
                test_read(buffer, &res);
                double elapsed = test_read(buffer, &res);
                test_read(buffer, &res);
#pragma omp critical
                {
                    curr_speed += MBYTES / 1024.0 / elapsed;
                }
#pragma omp barrier
#pragma omp single
                {
                    result = std::max<double>(curr_speed, result);
                }
                _mm_free(buffer);
            }
        }

    std::cout << result;

    return 0;
}
```

6.2.Запись:

```
#include <iostream>
#include <chrono>
#include <emmintrin.h>
#include <smmintrin.h>
#include <omp.h>
#include <vector>
#include <algorithm>
#include <cstring>
#include <cstdlib>


#ifdef _WIN32
#include <windows.h>    // for SetThreadAffinityMask
#elif __linux__
#include <sched.h>  // for sched_setaffinity
#endif
```

```
constexpr int ALIGN = 32;

constexpr size_t MBYTES = 512; // test array volume
constexpr size_t BUFFER_SIZE = 1024 * 1024 * MBYTES;
constexpr int TEST_TRIES = 50;

double test_write(__m128i *buffer, __m128i init_element) {
    double start = omp_get_wtime();
    for (size_t i = 0; i < BUFFER_SIZE / sizeof(__m128i); i++) {
        _mm_stream_si128(buffer + i, init_element);     // non-temporal write
    }
    double end = omp_get_wtime();

    return end - start;
}

void set_thread_affinity(int max_threads) {
#pragma omp parallel num_threads(max_threads)
    {
#ifdef _WIN32
    DWORD_PTR mask = (1 << omp_get_thread_num());
    SetThreadAffinityMask(GetCurrentThread(), mask);
#elif __linux__
    int cpu = omp_get_thread_num();
    cpu_set_t cpuset;
    CPU_ZERO(&cpuset);
    CPU_SET(cpu , &cpuset);
    sched_setaffinity(0, sizeof(cpuset), &cpuset);
#endif
    }
}

int main(int argc, char *argv[]) {
    int cores_num = 1;

    if(argc >= 2) {
        cores_num = atoi(argv[1]);
    }

    set_thread_affinity(cores_num);

    double curr_speed = 0;
    double result = 0;
#pragma omp parallel num_threads(cores_num)
```

```
        {
            for (int j = 0; j < TEST_TRIES; j++) {
#pragma omp single
                curr_speed = 0;
                __m128i* buffer = (__m128i*)_mm_malloc(BUFFER_SIZE, ALIGN);
                __m128i init_element = _mm_set_epi32(0, 1, 2, 3);

                memset(buffer, 0, BUFFER_SIZE);    // touch array to allocate
#pragma omp barrier
                test_write(buffer, init_element);
                double elapsed = test_write(buffer, init_element);
                test_write(buffer, init_element);

#pragma omp critical
                {
                    curr_speed += MBYTES / 1024.0 / elapsed;
                }
#pragma omp barrier
#pragma omp single
                {
                    result = std::max<double>(curr_speed, result);
                }

                _mm_free(buffer);
            }
        }

    std::cout << result;

    return 0;
}
```

6.3. **Копирование:**

```
#include <iostream>
#include <chrono>
#include <emmintrin.h>
#include <smmintrin.h>
#include <omp.h>
#include <vector>
#include <algorithm>
#include <cstring>
#include <cstdlib>

#ifdef _WIN32
#include <windows.h>    // for SetThreadAffinityMask
```

```
#elif __linux__
#include <sched.h>  // for sched_setaffinity
#endif

constexpr int ALIGN = 32;

constexpr size_t MBYTES = 512; // test array volume
constexpr size_t BUFFER_SIZE = 1024 * 1024 * MBYTES;
constexpr int TEST_TRIES = 50;

double test_copy(__m128i* buffer1, __m128i* buffer2) {
    double start = omp_get_wtime();
    for (size_t i = 0; i < BUFFER_SIZE / sizeof(__m128i); i++) {
        _mm_stream_si128(buffer2 + i, _mm_stream_load_si128(buffer1 + i));     //
 non-temporal read-write
    }
    double end = omp_get_wtime();

    return (end - start);
}

void set_thread_affinity(int max_threads) {
#pragma omp parallel num_threads(max_threads)
    {
#ifdef _WIN32
    DWORD_PTR mask = (1 << omp_get_thread_num());
    SetThreadAffinityMask(GetCurrentThread(), mask);
#elif __linux__
    int cpu = omp_get_thread_num();
    cpu_set_t cpuset;
    CPU_ZERO(&cpuset);
    CPU_SET(cpu , &cpuset);
    sched_setaffinity(0, sizeof(cpuset), &cpuset);
#endif
    }
}

int main(int argc, char *argv[]) {
    int cores_num = 1;

    if(argc >= 2) {
        cores_num = atoi(argv[1]);
    }

    set_thread_affinity(cores_num);
```

```
    double curr_speed = 0;
    double result = 0;
#pragma omp parallel num_threads(cores_num)
        {
            for (int j = 0; j < TEST_TRIES; j++) {
#pragma omp single
                curr_speed = 0;
                __m128i* buffer1 = (__m128i*)_mm_malloc(BUFFER_SIZE, ALIGN);
                __m128i* buffer2 = (__m128i*)_mm_malloc(BUFFER_SIZE, ALIGN);

                memset(buffer1, 0, BUFFER_SIZE);
                memset(buffer2, 0, BUFFER_SIZE);
#pragma omp barrier
                test_copy(buffer1, buffer2);
                double elapsed = test_copy(buffer2, buffer1);
                test_copy(buffer1, buffer2);
#pragma omp critical
                {
                    curr_speed += MBYTES / 1024.0 / elapsed;
                }
#pragma omp barrier
#pragma omp single
                {
                    result = std::max<double>(curr_speed, result);
                }

                _mm_free(buffer1);
                _mm_free(buffer2);
            }
        }

    std::cout << result;

    return 0;
}
```